

# E-Ticaret Sistemleri İçin Yapay Sinir Ağları ile Kıyafet Öneri Sistemi

## Clothing Recommendation System with Artificial Neural Networks for E-Commerce Systems

Ali Hüsameddin Ateş

Sakarya Üniversitesi, Fen Bilimleri Enstitüsü, Bilgisayar Mühendisliği, ali.ates4@ogr.sakarya.edu.tr

Dr.Öğr.Üyesi Hüseyin Eski

Sakarya Üniversitesi, Bilgisayar ve Bilişim Bilimleri Fakültesi, Bilgisayar Mühendisliği,  
heski@sakarya.edu.tr

**Öz:** Yapay zeka ve derin öğrenme algoritmalarının gelişmesiyle tüm sektörlerde bu algoritmalara dayalı sistemlerin kullanımı hızla artmaktadır. Tüketici sektörlerinin en büyüklerinden olan moda sektörü; çeşitliliği, hacmi ve müşterinin ürün seçiminde zorlanması bakımından yapay zeka algoritmalarıyla desteklenmeye en çok ihtiyaç duyulan sektörlerin başında gelmektedir. Bu bağlamda DeepFashion [1] veriseti ve Fast.ai [2, 3] kütüphanesiyle müşterilerin tarzına uygun bir öneri modeli geliştirilmesi amaçlanmıştır. Bu sayede müşteriler uzun arayışlara gerek kalmadan kendi stiline uygun bir moda kombini yapabilmeleri amaçlanmaktadır.

**Anahtar Kelimeler:** Derin Öğrenme, Kıyafet Tanıma, Moda Önerisi, Fast.ai, DeepFashion

**Abstract:** Recently with the development of artificial intelligence and deep learning algorithms, the use of systems based on these algorithms is increasing rapidly in all sectors. The fashion industry, which is one of the largest consumer sectors, is one of the sectors that most need to be supported with artificial intelligence algorithms in terms of its diversity, volume and the difficulty of the customer in product selection. In this context, it is aimed to develop a recommendation model suitable for customers' style with the DeepFashion [1]

dataset and Fast.ai [2, 3] library. In this way, it is aimed that customers can make a fashion combination suitable for their own style without the need for long searches.

**Keywords:** Deep Learning, Clothes Recognition, Fashion Advice, Fast.ai, DeepFashion

### 1. Giriş

Artan ürün sayısı ve çeşitliliğine bağlı olarak günümüz klasik e-ticaret sistemlerinde sıradan filtrelerle istenilen ürünü arayıp bulmak gittikçe zor ve uzun süren bir iş haline gelmiştir.

Gelişen dünyada sayısız kıyafet kategorisi ve stili bulunmaktadır. Bu durum insanların avantajına görünse de çoğu zaman bir karmaşa ve zaman kaybına yol açmaktadır. İnsanlar sosyal medyadan, dergilerden, medya unsurlarından gördükleri kıyafetleri satın almak istediklerinde uzun arayışlar içerisine girerek çoğu zaman amaçlarına ulaşamamaktadır.

Moda gibi büyük bir sektörün artık daha da dijitalleşerek insanların gördükleri her kıyafeti veya benzerini bulabilecek bir entegrasyona ihtiyacı vardır.


Bu açığı kapatacak yazılımlar gelceğin yapay zeka uygulamalarının sosyal moda yapbozunun bir parçası olacaktır.

2013 yılında bir McKinsey raporu [4], Amazon satış gelirinin yüzde 85'inden fazlasının kişiselleştirilmiş tavsiyelerden elde edildiğini belirtmiştir. O zamandan beri kişiselleştirilmiş önerilerin kullanımı artarak devam etmiştir ve ortalama olarak bugünün kişiselleştirilmiş önerileri, son bir Salesforce raporuna göre perakende satış gelirlerinin yüzde 27'sini oluşturmaktadır. [5]

Yapay zeka destekli öneri motorlarının geliştirilmesiyle birlikte öneri motorlarının moda ve giyim alanlarında daha yaygınlaştığını görülmekte; mevcut uygulamalar müşterilere gardırop önerileri göstermek için insanların giysi, ayakkabı ve moda aksesuarlarında müşterinin stilini tespit etmeye çalışmakta ve daha satın alınabilir öneriler göstermeye çalışmaktadır. [6] Bu tür öneri motoru uygulamaları bağımsız olmasına rağmen yaygın markaların sitelerine entegre edilebilmektedir.

Gelecek asrın yapay zeka uygulamalarına entegre olarak çalışması hedeflenen bu tür projeler sayesinde artık klasik arama alışkanlıklarından ziyade anında incelemeye dayalı gezinme sistemleri ile daha sistematik, kararlı, hızlı ve isabetli arama motorları geliştirilmelidir.

Kıyafet tavsiyesi üzerine sektörde dünya çapında hizmet veren başlıca sistemler: Syte.ai [7], ViSenze [8], FindMine [9], 3DLook [10], True Fit [11] ve Secret Sauce [12] firmalarıdır. Uygulamaların genel çalışma biçimine bakıldığında: kıyafet tespiti, tanımlanması ve müşterilere ilgili kıyafetlerin tavsiye edilmesi amacıyla; kategori tespiti, alt tip tespiti, renk tespiti ve desen tespiti gibi fonksiyonlara bulunmaktadır.



Şekil 1. Wardrobe Expert Uygulaması

Kıyafet öneri sistemleri konusunda bazı araştırmacılar ürüne ait dijital resmin CCPV (Color-Class Profile Vector) özelliklerini çıkarmak amacıyla ürünün Red, Green, Blue, Yellow, White ve Black renk yoğunluk değerlerini inceleyerek o ürünü tanımlamaya çalışmışlardır. [13]

Araştırmacılar ayrıca kullanıcıların moda ilgilerini tahmin etmede yüz özellikleri, vücut şekilleri, kişisel tercihleri, konumları ve konuma özel giyme durumları gibi kullanıcı özelliklerini de dikkate alarak bir Feature Map oluşturmuşlar ve cinsiyete bağlı olarak kombin eşleştirme tavsiyeleri sunmuşlardır. [14]

Diğer bazı araştırmacılar ise kişinin önceki tercihlerine, davranışlarına, tarzına ve cinsiyetine bağlı olarak bir semantik (anlamsal) özellik vektörü çıkarma yoluna giderek daha spesifik bir öneri sunmayı amaçlamışlardır. [15]

Geliştirilen bir diğer yöntem ise örtük kullanıcı moda profili oluşturma toplama sistemidir (The implicit user fashion profiling collection system). Kullanıcılara rastgele üst ve alt stildeki kıyafetlerin gösterildiği sistemde kullanıcı, resimlerden tercih ettiği stili seçerek örtük kullanıcı moda profili oluşturma sistemi ile stil görüntü profili oluşturulmakta ve toplanan bireysel profil aracılığıyla sistem kullanıcıdan tercihleri doğrultusunda üst ve alt kıyafet tarzı modelini öğrenmektedir. [16]

Kıyafet öneri sistemlerinde toplanan veriler doğrultusunda modelin eğitilmesi için yaygın olarak evrişimsel sinir ağları kullanılmaktadır [1, 17, 18]. Bir evrişimli sinir ağı (CNN), çoklu evrişimli katmanlardan oluşur. Bu katmanlar, evrişimli katmanlar, filtre boyutu ve tam bağlantılı katmanlar açısından farklılık gösterebilir. Çalışmalarda en yüksek doğrulukla daha iyi sonuçlar elde etmek için ağın derinliğini artırılır veya azaltılır. Verilerin boyutunu azaltmak için isteğe bağlı bir havuzlama katmanı vardır. [19] Havuzlama katmanının en yaygın biçimi, genellikle  $2 \times 2$  ve  $4 \times 4$  arasında değişen maksimum havuzlamadır. Softmax, Sigmoid, ReLU ve TanH, CNN için ayrı ayrı veya yığın şeklinde kullanılabilen en yaygın aktivasyon fonksiyonlarıdır. [20] Adam ve stokastik gradyan (SGD), CNN modellerinin hiper parametrelerinin ayarlanmasında kullanılan iki yaygın optimizasyon algoritmalarıdır. [21] CNN, güçlü özellik çıkarma ve görüntü sınıflandırma yetenekleri nedeniyle öneri sistemlerinde yaygındır.

CNN ile yapılan bir çalışmada görüntülerin ve detaylı özelliklerin öğrenilmesi için estetik tabanlı bir giyim öneri sistemi kullanılmış; bu amaçla Red, Green, Blue değerlerine duyarlı bir evrişimli sinir ağı ile birlikte Hue, Saturation, Duetones gibi alt tonları kullanan birleştirilmiş bir network önerilmiştir. [22]

Michael A. Halstead, Multimodal Clothing Recognition adlı çalışmada düşük çözünürlüklü resimleri de baz alarak bölgesel alan taramaya dayalı bir yaklaşım sergilemiştir. Görüntüdeki kıyafetlerin sınırlarını belirleyebilmek için gövde, kollar ve bacakların hariç tutulduğu ve giysilerin tarandığı bir segmentasyon yöntemi kullanmıştır. [23]

## 2. Metodoloji

Makine öğrenmesi alanında günümüzde nesneleri tanımlamak amacıyla geliştirilmiş

birçok algoritma mevcuttur. Template matching, feature detection ve contextual classification gibi bunlardan en klasik olanları, nesneleri bir geometrik şekil olarak değerlendirerek o şekle özel ve onu diğer nesnelerden ayıran bazı matematiksel özellikler keşfederek (feature extraction) makinenin o nesneyi diğerlerinden ayırtmasını amaçlar [24]. Bu algoritmaların dezavantajı ise çıkartılacak feature'ların sınırlı olması ve genel geçer olarak her yerde bu feature'ların kullanılamamasıdır. Daha gelişmiş algoritmalar olarak Yapay Sinir Ağları (Artificial Neural Network) algoritmaları ise insan eliyle feature çıkartmak yerine bu işi makineye bırakmaktadır ve sayıca çok daha fazla feature elde edilebilmektedir [25].

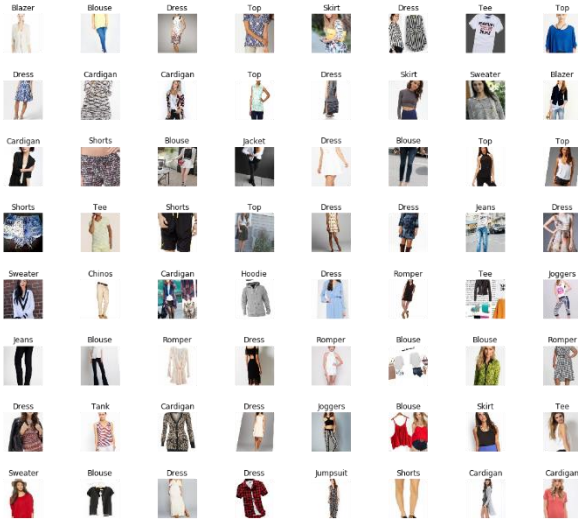
Derin öğrenme (Deep Learning) yöntemi ise yine yapay sinir ağı mimarilerini kullanır, bu nedenle derin öğrenme modellerine genellikle derin sinir ağları denir. "Derin" terimi genellikle sinir ağındaki gizli katmanların sayısını ifade eder. Geleneksel sinir ağları yalnızca 2-3 gizli katman içerirken derin ağlar yüzlerce katman içerebilir. Derin öğrenme modelleri manuel özellik çıkarımına gerek kalmadan özellikleri doğrudan verilerden öğrenen, geniş özellik kümesine sahip sinir ağı mimarileri kullanılarak eğitilir. [26]

Derin sinir ağlarının en popüler türlerinden biri evrişimli sinir ağlarıdır (Convolutional Neural Network, CNN veya ConvNet). Bir CNN, öğrenilen özellikleri girdi verileriyle birleştirir ve 2B evrişim katmanlarını kullanır, bu mimari görüntüler gibi 2B verileri işlemeye çok daha uygundur. [27]

CNN'ler manuel özellik çıkarma ihtiyacını ortadan kaldırır, bu nedenle görüntüleri sınıflandırmak için kullanılan özellikleri tanımlanması gerekmez. CNN, özellikleri konvolüsyon matrisi ile görüntüyü tarayarak doğrudan görüntülerden çıkararak çalışır.

Özellikler önceden eğitilmemesine rağmen ağ, bir görüntü veriseti üzerinde eğitilirken bir yandan da öğrenir. Bu otomatikleştirilmiş özellik çıkarma derin öğrenme modelleri ile nesne sınıflandırma gibi bilgisayarla görme görevleri için oldukça kullanışlıdır. [28]

Bu çalışmada kullanılan evrişimli sinir ağını eğitmek için DeepFashion [1] sınıflandırılmış kıyafet dataseti kullanılmıştır. Kullanılan Large-Scale Fashion Dataset, Hong Kong Çin Üniversitesi Multimedia Laboratuvarı tarafından hazırlanan geniş çaplı bir resim veritabanıdır. İçerisinde 289,222 adet çeşitli kategorilerde kıyafet resimleri bulunmaktadır. 50 ana kategori ve 1000 adet kıyafet alt kategorisi ile birlikte toplamda 5618 adet kategori bulunmaktadır.




Şekil 2. Large-Scale Fashion Dataset

Verisetindeki kategorilere ait resimleri eğitmek amacıyla projede Fast.ai [2, 3] kütüphanesi kullanılmıştır. Fast.ai, Python dilinde yazılmış ve Pytorch üzerine inşa edilmiş gelişmiş bir yapay zeka kütüphanesidir.

Fast.ai evrişimli ağ mimarisi modeli genel olarak üç yapı taşından oluşur. İlk olarak özelliklerin öğrenilmesi için evrşimsel katman yer alır; ikinci olarak görüntüyü yeniden örneklemek, boyutu azaltmak ve hesaplama maliyetini düşürmek için havuzlama katmanı

bulunur. Son olarak ise birkaç kez evrişimli katmandan ve pooling katmanından geçen ve matris halinde olan görseli düz bir vektör haline getiren tam bağlı katmanlar bulunur. [29].



Şekil 3. Fast.ai CNN Architecture [29]

Fast.ai mimarisinde ilk vermemiz gereken parametre ağı gövdesi olarak kullanılacak olan, önceden eğitilip ağırlıkları optimize edilmiş bir mimaridir. Projede Resnet34 mimarisi ile transfer öğrenme tercih edilmiştir. Daha sonra optimize edilmiş ağırlıkların kullanıldığı Şekil 3'teki mimariye verisetindeki tüm resimler girdi olarak verilir ve çıkan ağırlıklar Cross Entropy hata fonksiyonundan geçirilerek kategorilerin olasılıkları hesaplanmaktadır.

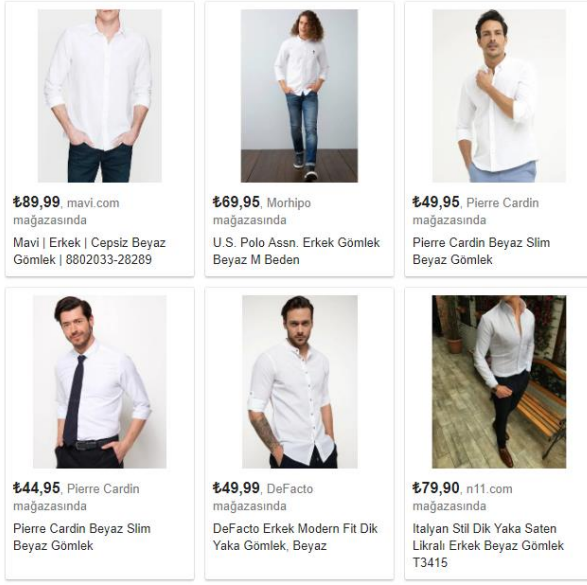
epoch	train loss	valid loss	accuracy
1	1.632115	1.474118	0.561742
2	1.548713	1.408220	0.583295
3	1.512822	1.369032	0.596267
4	1.450622	1.345870	0.601440
5	1.445819	1.308995	0.612246
6	1.361442	1.289868	0.617319
7	1.370456	1.276496	0.621509
8	1.364946	1.272343	0.621870

Tablo 1. Top-1 Accuracy Başarımı

top-1 accuracy	top-3 accuracy	top-5 accuracy
%62.1870	%84.4762	%91.5972

Eğitim sonucu oluşturulan modeli test aşamasında, görüntüdeki sınıfın %100 tahmini anlamına gelen top-1 başarımı %62, doğru tahminin ilk üç tahmin arasında olduğu top-3 başarımı %84 ve doğru tahminin ilk beş tahmin

arasında olduğu top-5 başarımı %91 olarak elde edilmiştir.



Şekil 4. Rasgele Tahminler ve Sonuçları

### 3. Araştırma Sonuçları ve Tartışma

Moda öneri sistemlerinde eğitilen modelin kullanıcının verdiği rasgele bir girdi resminden sınıfları ve özellikleri doğru tahmin edebilmesi için kullanıcıların her zaman yüksek çözünürlük ve detaydaki resimleri yüklemesi beklenemeyeceğinden; modelin çok daha detaylı verisetleriyle, devasa transfer ağlarıyla daha fazla kategori ve özelliklerle eğitilmesi ve geliştirilmesi gerekmektedir.

Elde edilen sonuçlar deneysel manada yeterli gibi görünse de sektörel kullanım için deneysel bir çalışma kapsamındadır.

Kullanılan Fast.ai kütüphanesi ve Resnet34 mimarisi dışında diğer Tensorflow, PyTorch Coco, MxNet, Caffe gibi kütüphanelerle ve diğer LeNet, AlexNet, VGGNet, ZFNet gibi transfer öğrenme mimarileri ile veriseti eğitilip farklı sonuçlar değerlendirilebilir.

Verisetindeki girdi sayısının büyüklüğü ve donanımsal kaynakların sınırlı olması sebebiyle

sınırlı sayıda döngü (Epoch) ile yapılan çalışma çok daha güçlü donanımlarla daha çok döngü sayısına ulaşarak doğruluk oranında iyileşmeye gidilebilir.

### 4. Kaynakça

- [1] Z. L. P. Q. S. W. X. T. X. Liu, "DeepFashion: Powering Robust Clothes Recognition and Retrieval with Rich Annotations".
- [2] "https://www.fast.ai/", [Online].
- [3] S. G. Jeremy Howard, "Fastai: A Layered API for Deep Learning," *Information*, 2020.
- [4] [Çevrimiçi]. Available: <https://www.mckinsey.com/industries/retail/our-insights/how-retailers-can-keep-up-with-consumers>. [Erişildi: 2022].
- [5] [Çevrimiçi]. Available: <https://www.salesforce.com/form/commerce/power-of-personalized-shopping/>. [Erişildi: 2022].
- [6] [Online]. Available: <https://www.emerald.com/insight/content/doi/10.1108/IJCST-09-2015-0100>. [Accessed 2022].
- [7] [Online]. Available: <https://www.syte.ai/>. [Accessed 2022].
- [8] [Online]. Available: <https://www.visenze.com/>. [Accessed 2022].
- [9] [Online]. Available: <https://findmine.com/>. [Accessed 2022].
- [10] [Online]. Available: <https://3dlook.me/>. [Accessed 2022].
- [11] [Online]. Available: <https://www.truefit.com/>. [Accessed 2022].
- [12] [Online]. Available: <https://secretsaucegroup.com/>. [Accessed 2022].

- [13] K. Zempo and U. Sumita, in *Identifying Colors of Products and Associated Personalized Recommendation Engine in e-Fashion Business.*, New York, NY, USA,, 2015, p. 335–346.
- [14] J. Jo, S. Lee, C. Lee, D. Lee and H. Lim, "Development of fashion product retrieval and recommendations model based on deep learning," *Electronics*, p. 508, 2020.
- [15] L. W. E. C. Z. L. V. W. Z. Q. L. Min Hou, "Explainable Fashion Recommendation: A Semantic Attribute Region Guided Approach," *arXiv:1905.12862v2 [cs.LG]*, 27 Jun 2019.
- [16] J. L. S. L. C. L. D. L. H. Jo, "Development of Fashion Product Retrieval and Recommendations Model Based on Deep Learning," *Electronics*, 2020.
- [17] Z. Y. H. L. X. Hu, "Clothing segmentation using foreground and background estimation based on the constrained Delaunay triangulation," 2008.
- [18] D. Z. C. W. Q. F. L. X. X. Zhang, "Unabridged adjacent modulation for clothing parsing," 2022.
- [19] H. K. Hossein Gholamalnejad, "Vehicle classification using a real-time convolutional structure based on," *Expert Systems With Applications*, 2021.
- [20] Z. W. Q. M. H. S. Yang Liu, "Multistability analysis of delayed recurrent neural networks with a," *Neural Networks*, 2022.
- [21] X. G. T. Y. Y. D. L. Y. Z. Wengang Zhang, "Application of machine learning, deep learning and optimization," *Gondwana Research*, 2022.
- [22] H. Z. X. H. X. C. L. X. Z. Q. Wenhui Yu, "Aesthetic-based Clothing Recommendation," *WWW '18: Proceedings of the 2018 World Wide Web Conference*, 2018.
- [23] S. D. S. S. Y. T. F. Michael A. Halstead, "Multimodal clothing recognition for semantic search in unconstrained," *Journal of Visual Communication and Image Representation*, 2019.
- [24] A. R. D. L. Y. T. Z. A. P. Y. B. Yanzhou Fu, "Machine learning algorithms for defect detection in metal laser-based," *Journal of Manufacturing Processes*, 2022.
- [25] G. S. BARIŞ GÖKÇE, "İnsansız Kara Araçlarından Kamera ile Görüntülenen Hareketli Nesnelerin Sınıflandırılması Amacıyla Geliştirilen Görüntü İşleme Tabanlı Yöntemlerin Karşılaştırılması," *Afyon Kocatepe Üniversitesi Fen ve Mühendislik Bilimleri Dergisi*, 2018.
- [26] A. S. Y. Fatma Gülşah TAN, "Derin Öğrenme Teknikleri ile Nesne Tespiti Ve Takibi Üzerine Bir İnceleme," *Avrupa Bilim ve Teknoloji Dergisi*, vol. 0, no. 25, pp. 159 - 171, 2021.
- [27] B. ELMAS, "Evrişimli Sinir Ağları ile Mantar Görüntülerinden Mantar Türlerinin Transfer Öğrenme Yöntemiyle Tanımlanması," *Süleyman Demirel Üniversitesi Fen Bilimleri Enstitüsü Dergisi*, vol. 25, no. 1, pp. 74 - 88, 2021.
- [28] B. ELMAS, "TÜRKİYE'DEKİ KELEBEK TÜRLEİNİN BASAMAKLI EVRİŞİMLİ SINIR AĞLARI İLE SINIFLANDIRILMASI," *Konya mühendislik bilimleri dergisi*, vol. 9, no. 3, pp. 568 - 587, 2021.
- [29] A. A. H. M. Mohammed Kayed, "Classification of Garments from Fashion MNIST Dataset Using CNN LeNet-5 Architecture," *Computer Science*, 2020.